HEALTHCARE ANALYTICS PORTFOLIO PLAN

תוכנית עבודה: אופטימיזציה של מסלול מטופל וחיזוי אשפוזים ממושכים

פרויקט אנליטי מקיף מקצה לקצה בסטנדרט תעשייה (Modern Data Stack) לתחום הבריאות

⏱ **משך זמן מומלץ:** 8 שבועות (6–8 שעות שבועיות) | 📊 **סביבה:** Google BigQuery + dbt Core + Python + R + BI | 🏥 **תקן קליני:** HL7 FHIR & SNOMED-CT

1. שאלת המחקר והערך העסקי-קליני

בעולם הרפואי המודרני, צוואר הבקבוק המשמעותי ביותר של בתי חולים וקופות החולים הוא העומס במלר"ד (מיון) והמעבר לאשפוז במחלקות. אשפוזים ממושכים מעבר למצופה Extended Length of Stay - LOS) מעל 7 ימים) מייצרים עומס תפעולי חריג, מגדילים את הסיכון לזיהומים צולבים ומייקרים את עלות הטיפול במאות אחוזים.

> **השאלה הקלינית-עסקית שהפרויקט עונה עליה:** כיצד ניתן לזהות כבר בשלב הקבלה למיון אילו מטופלים נמצאים בסיכון הגבוה ביותר לאשפוז ממושך חריג, ואילו גורמים תפעוליים וקליניים משפיעים ביותר על זמני ההמתנה למחלקה?

2. מפת הדרכים: 7 שלבים ב-8 שבועות

הפרויקט בנוי בדיוק לפי שרשרת הערך של צוותי דאטה בארגוני בריאות מובילים (כגון כללית, מכבי, שיבא ARC וחברות Health-Tech):

שלב	מה בונים בפועל?	כלים וטכנולוגיות	שבועות	תוצר מדיד
1. מקורות דאטה	הפקת 5,000 מטופלים סינתטיים ופרסור מבנה ה-FHIR JSON	Synthea, Python, JSON	שבועות 1–2	טבלאות Parquet מנורמלות
2. מחסן נתונים	הקמת תשתית ענן, טעינת טבלאות וכתיבת שאילתות מורכבות	Google BigQuery, SQL	שבוע 3	סכמת נתונים מאומתת ב-Cloud
3. מידול אנליטי	טרנספורמציות, בדיקות איכות נתונים ותיעוד שושלת דאטה (Lineage)	dbt Core, Git	שבוע 4	מודל עובדות `fct_admissions`
4. ניתוח סטטיסטי	בדיקת השערות קליניות ומודל רגרסיה לבחינת יחסי סיכויים	R, Python (Pandas/Stats)	שבוע 5	דו"ח סטטיסטי + Odds Ratios
5. מודל חיזוי	מודל ML לסיווג סיכון מטופל בעת השחרור מהמיון	scikit-learn (ML Pipeline)	שבוע 6	ROC-AUC > 0.78 + חשיבות משתנים
6. דשבורד מנהלים	מסך תפעולי אינטראקטיבי לניטור עומסים ומטופלים בסיכון	Tableau או Power BI	שבוע 7	דשבורד חי ומעוצב לתיק עבודות
7. פרסום והגשה	כתיבת README מקצועי ב-GitHub ותרגיל סיכום ב-Excel	GitHub, Excel (XLOOKUP)	שבוע 8	לינק חי ב-CV ופוסט LinkedIn

💡 יתרון בראיונות עבודה

שימוש בתקן הבינלאומי **HL7 FHIR** מוכיח היכרות עמוקה עם עולם הבריאות האמיתי, מעבר לקבצי CSV פשוטים מ-Kaggle.

🛡 מניעת דליפת מידע (Data Leakage)

המודל משתמש אך ורק במשתנים הידועים ברגע הקבלה לאשפוז – נקודה קריטית שמראיינים בכירים בודקים בכל מבחן בית.

חלק א': תשתית הנתונים ומידול בענן (שבועות 1–4)

שבוע 1: הפקת נתוני FHIR והבנת המבנה הקליני

Synthea & FHIR Basics

- **הקמת מאגר פרויקט ב-GitHub:** פתיחת מאגר ציבורי בשם `patient-flow-analytics` הכולל קובץ `.gitignore` (חובה לחסום העלאת נתונים מעל 100MB).
- **הרצת Synthea:** יצירת קבוצת ביקורת של כ-5,000 מטופלים באמצעות פקודת Java עם Seed קבוע לשחזור תוצאות: `./run_synthea -s 42 -p 5000 --exporter.fhir.export=true`.
- **מיפוי משאבי FHIR מרכזיים:** לימוד המבנה ההיררכי של משאב המטופל (`Patient`), ביקורים (`Encounter`: הפרדה בין `EMER` ל-`IMP`), ואבחנות (`Condition`).
- **חקירה ידנית (Manual Trace):** פתיחת קובץ JSON בודד ופיענוח מסלול המטופל מקבלתו במיון ועד למחלקת האשפוז ללא קוד.

שבוע 2: עיבוד ופרסור נתוני JSON באמצעות Python

Python, Pandas, Parquet

- **חילוץ נתונים מובנה:** כתיבת מודול פייתון המפרק את ה-FHIR Bundles ומוציא טבלאות נפרדות: מטופלים, ביקורים, מדדים ואבחנות.
- **טיפול בזהויות מקושרות:** ניקוי קידומות מזהים (כגון `urn:uuid:`) על מנת לאפשר קישורים (Joins) תקינים בין הטבלאות.
- **שמירת נתונים יעילה:** ייצוא הטבלאות המעובדות לקובצי Parquet השומרים על טיפוסי נתונים מדויקים ומאפשרים טעינה מהירה.
- **תיעוד מילון מונחים:** יצירת קובץ תיעוד המסביר קודי מיון בינלאומיים (SNOMED-CT לאבחנות ו-LOINC למעבדות) והשוואתם ל-ICD-10.

שבוע 3: העלאה לענן וכתיבת שאילתות מתקדמות ב-BigQuery

Google BigQuery & Window Functions

- **הקמת BigQuery Sandbox:** יצירת פרויקט חינמי ב-Google Cloud והקמת Dataset ייעודי בשם `raw_healthcare` באזור אחיד (EU).
- **בניית סכמה מוגדרת (Explicit Schema):** הגדרת טיפוסי נתונים קשיחים (Timestamps, Strings, Integers) למניעת שגיאות המרה אוטומטיות.
- **חישובי חלון קליניים:** כתיבת שאילתות SQL מתקדמות תוך שימוש ב-`LAG` ו-`LEAD` עם `PARTITION BY patient_id` לחישוב זמני מעבר ממיון לאשפוז.
- **מדידת זמנים מדויקת:** חישוב גיל בעת ההגעה באמצעות `DATE_DIFF` והימנעות משימוש בתאריך הנוכחי של הריצה.

שבוע 4: מידול נתונים אנליטי ובדיקות איכות ב-dbt Core

dbt Core, Data Quality & Tests

- **ארכיטקטורת Staging:** יצירת מודלי הכנה מנורמלים (`stg_encounters`, `stg_patients`) ללא לוגיקה עסקית מורכבת.
- **בניית טבלת עובדות מרכזית:** יצירת המודל `fct_inpatient_stays` הכולל שורה לכל אשפוז, חישוב משך השהייה ברוטו, ודגל `is_extended_stay` (מעל 7 ימים).
- **בדיקות איכות נתונים מובנות:** הגדרת בדיקות `unique` ו-`not_null` בקובץ הסכמה.
- **בדיקה עסקית מותאמת אישית:** כתיבת בדיקה המוודאת שמועד השחרור תמיד מאוחר ממועד הקבלה (`discharge_time > admission_time`).

🚩 **ציון דרך אמצע (שבוע 4):** בשלב זה מאגר ה-GitHub שלך כולל פייפליין נתונים פעיל בענן ומודלים מתועדים ב-dbt. ניתן כבר להתחיל לציין את הפרויקט בקורות החיים כפרויקט בתהליך (Work in Progress).

חלק ב': ניתוח סטטיסטי, חיזוי ודשבורד מנהלים (שבועות 5–8)

שבוע 5: חקירה מעמיקה ובדיקת השערות סטטיסטיות

Python, R, Statistical Inference

- **ניתוח פילוחים ב-SQL:** בדיקת שיעורי האשפוז הממושך לפי מגדר, עשירוני גיל, מחלקת אשפוז, ושעת הקבלה (יום מול לילה וסופי שבוע).
- **בדיקות מובהקות ב-R:** הרצת מבחן Chi-Square לבחינת התלות בין ריבוי מחלות רקע (Multimorbidity) לבין שהייה ממושכת.
- **רגרסיה לוגיסטית וחישוב סיכונים:** התאמת מודל `glm` להערכת יחסי סיכויים מותאמים (Adjusted Odds Ratios) והסבר המשמעות הקלינית בשפה עסקית פשוטה.
- **ויזואליזציה מקצועית:** הפקת תרשימי התפלגות ב-Seaborn/Matplotlib עם כותרות המדגישות את המסקנה (Takeaway) ולא רק את שמות הצירים.

שבוע 6: בניית מודל חיזוי סיכון למטופל במיון

scikit-learn & Feature Engineering

- **הנדסת מאפיינים נקייה מדליפות:** יצירת מאפיינים שנוצרו טרם ההחלטה על אשפוז בלבד (מספר אבחנות כרוניות, גיל, מספר ביקורי עבר ב-12 החודשים האחרונים).
- **חלוקת דאטה מבוססת מטופלים:** שימוש ב-`GroupShuffleSplit` כדי להבטיח שאותו מטופל אינו מופיע גם ב-Train וגם ב-Test.
- **אימון מודלים והתמודדות עם חוסר איזון:** אימון Logistic Regression ו-Random Forest תוך שימוש בפרמטר `class_weight='balanced'`.
- **הערכת ביצועים קלינית:** דיווח על מדדי ROC-AUC ו-Recall (תעדוף זיהוי מרבי של מטופלים בסיכון על פני דיוק כללי מטעה).

שבוע 7: בניית דשבורד מנהלים אינטראקטיבי

Tableau Public / Power BI

- **ארכיטקטורת מסך יחיד (Executive Overview):** בניית דשבורד ברור וממוקד המציג בראש העמוד מדדי KPI: סך קבלות, שיעור שהייה מעל 7 ימים, וזמן חציוני במיון.
- **ניתוח מגמות וצווארי בקבוק:** תרשים קווי של עומסי קבלה לאורך ציר הזמן לצד התפלגות זמני המתנה לפי מחלקה קולטת.
- **כרטיסיית ניהול סיכונים:** טבלה אינטראקטיבית המציגה למנהל התורן רשימת מטופלים הנמצאים כעת בסיכון גבוה לאשפוז ממושך.
- **עקרונות עיצוב נקיים:** הגבלת פלטת הצבעים לגוונים ניטרליים עם צבע הדגשה יחיד (כתום/טורקיז כהה) למטופלים הדורשים התערבות.

שבוע 8: משימת Excel, תיעוד סופי ב-GitHub וסגירת תיק עבודות

Excel, GitHub README, Portfolio

- **סימולציית מבחן בית ב-Excel:** יצירת קובץ ניתוח נתונים המבוסס על טבלאות ציר (Pivot Tables) ושימוש בפונקציות `XLOOKUP` ו-`INDEX/MATCH`.
- **כתיבת README מוכוון תוצאות:** פתיחה בצילום מסך של הדשבורד, שאלת המחקר, 3 מסקנות מרכזיות בולטות, והסבר על מגבלות הנתונים הסינתטיים.
- **בדיקת שחזור (Reproducibility):** שיבוט המאגר לתיקייה חדשה והרצת כל שלבי הפרויקט מחדש לפי ההוראות כדי לוודא שאין שגיאות.

3. שילוב הפרויקט בקורות החיים והצגתו למגייסים

האופן שבו את מתארת את הפרויקט בקורות החיים ובפרופיל הלינקדאין קובע האם המגייס יראה בך ג'וניורית שלמדה קורס, או אנליסטית שיודעת לפתור בעיות עסקיות אמיתיות.

נוסח מומלץ לקורות החיים (סעיף פרויקטים):

ED Patient Flow & Extended Stay Analytics (End-to-End Healthcare Project)

- פיתוח פייפליין מלא מנתוני מטופלים גולמיים בתקן HL7 FHIR (5,000 מטופלים) באמצעות Python עד לטעינה ומידול ב-Google BigQuery.
- בניית מודל נתונים אנליטי ב-dbt Core כולל בדיקות איכות נתונים מותאמות אישית ותיעוד שושלת נתונים (Data Lineage).
- ביצוע ניתוח סטטיסטי ב-R לזיהוי גורמי סיכון קליניים (Logistic Regression, Odds Ratios) ואימון מודל scikit-learn לחיזוי אשפוז ממושך (AUC 0.82).
- אפיון והקמת דשבורד מנהלים אינטראקטיבי ב-Power BI המאפשר ניטור עומסים בזמן אמת והתרעה מוקדמת על צווארי בקבוק.

רשימת מיומנויות טכנולוגיות (Skills Line ב-CV):

Data & BI: SQL (BigQuery, PostgreSQL), dbt Core, Power BI / Tableau, Excel (Advanced, Power Query)
Programming & Stats: Python (Pandas, NumPy, scikit-learn), R (Statistical Modeling, ggplot2)
Healthcare Standards: HL7 FHIR, SNOMED-CT, LOINC, Length of Stay (LOS) Modeling, Clinical KPIs

4. הכנה לראיונות עבודה: תסריט 2 הדקות

כשמראיין אומר לך: *"ספרי לי על פרויקט שביצעת"*, הציגי את המבנה הבא (בעיה ← פעולה אנליטית ← תובנה ← תוצאה):

1. **הבעיה:** "חיפשתי להתמודד עם אחת הבעיות הקשות בבתי חולים – עומסים במיון ואשפוזים ממושכים שמייקרים את הטיפול ומסכנים מטופלים."
2. **הנתונים והתשתית:** "הפקתי נתוני FHIR בינלאומיים, עיבדתי אותם ב-Python וטענתי למחסן נתונים ב-BigQuery. בעזרת dbt יצרתי מודל מסודר עם בדיקות איכות נתונים קפדניות."
3. **התובנה:** "גיליתי באמצעות רגרסיה ב-R כי שילוב של סוכרת ומחלות לב הכפיל את הסיכוי לאשפוז מעל 7 ימים, אך עיקר צוואר הבקבוק התפעולי נבע מקבלה בשעות הלילה שעיכבה שחרורים ב-36 שעות בממוצע."
4. **התוצר:** "בניתי מודל חיזוי ב-scikit-learn שהתריע על חולים בסיכון גבוה עם שחרורם מהמיון, ושיקפתי את כל המדדים בדשבורד מנהלים ייעודי."

5. יעדי הגשת מועמדות מומלצים בישראל

קופות חולים ומערך הבריאות הציבורי

צוותי Data & BI בכללית, מכבי, מאוחדת ולאומית; משרד הבריאות; יחידות אנליטיקה ו-BI בבתי חולים מובילים (איכילוב, שיבא, הדסה, רמב"ם).

חברות Health-Tech ו-Pharma

חברות ישראליות ובינלאומיות המפתחות מערכות תומכות החלטה קלינית, ניתוח נתוני עתק (Real World Data), וציוד רפואי דיגיטלי.